



UNIVERSIDAD
DE LA REPÚBLICA
URUGUAY



Introducción a la Ciencia de Datos

Proyecto final

Clasificación de días de consumo HVAC bajo, medio y alto

Dataset LBNL Building 59

Bruno Fabre Hernandez
Santiago Burgueño Paysse

Julio de 2026

Repositorio: <https://github.com/santiago0111/introcd-2026-grupo-10>

Índice

1. Dataset y calidad de datos	2
2. Pregunta del proyecto	2
3. Proceso propuesto	2
4. Consideraciones éticas	4

1. Dataset y calidad de datos

El dataset es *LBNL Building 59*, un edificio de oficinas en Berkeley (California), con mediciones reales entre 2018 y 2020 en 27 archivos CSV de series temporales (consumo energético, clima, operación HVAC, temperatura interior, CO₂, WiFi, ocupación). Se usa un subconjunto: `ele.csv` (potencia HVAC de ala norte y sur, `hvac_total` = `hvac_N` + `hvac_S`) y `site_weather.csv` (temperatura exterior, humedad, punto de rocío, radiación solar).

Problemas de calidad relevantes: las variables tienen frecuencias de medición distintas (1 a 15 minutos) y unidades no homogéneas; los datos ya vienen imputados y con outliers corregidos, por lo que no son crudos; ocupación y WiFi tienen cobertura parcial y no se pueden usar de forma confiable; y 2020 tiene un comportamiento atípico por la pandemia. Por esto se trabaja a escala diaria, exigiendo al menos 95 % de cobertura de mediciones por día y dejando 2020 fuera del análisis.

2. Pregunta del proyecto

¿Se puede clasificar un día como de consumo HVAC bajo, medio o alto a partir de las condiciones climáticas exteriores? Es un problema de clasificación multiclase supervisada, con clases ordinales (bajo < medio < alto) definidas por percentiles anuales del consumo diario (evita que un umbral fijo quede desactualizado si cambia el nivel general de consumo de un año a otro).

3. Proceso propuesto

El proceso que se seguiría:

1. **Agregar las series a escala diaria.** Los datos vienen cada 15 minutos; se resumen a un valor por día (consumo HVAC, temperatura media/máxima/mínima, humedad, punto de rocío, radiación) porque la pregunta es sobre “días”, no sobre instantes, y agregar reduce ruido de alta frecuencia y volumen de datos.
2. **Explorar la relación entre clima y consumo.** Antes de modelar conviene mirar cómo se comportan las variables entre sí (Figura 1), para detectar problemas como la mezcla de regímenes de calefacción y enfriamiento que diluyen la relación real.
3. **Definir las clases bajo/medio/alto por percentiles anuales.** Se necesitan clases balanceadas para poder entrenar y evaluar de forma justa. Calcularlas por año evita que un cambio en el nivel general de consumo deje un año entero metido en una sola clase.
4. **Entrenar con partición temporal.** Un año para entrenar, el siguiente para evaluar. Es más exigente que un split aleatorio porque obliga al modelo a generalizar hacia un período que no vio, que es la situación real en la que se usaría un modelo de este tipo (predecir días que todavía no pasaron).
5. **Evaluar con matriz de confusión, accuracy y F1 macro.** El accuracy solo puede engañar si las clases no quedan perfectamente parejas en la prueba; F1 macro pondera igual a las tres clases, y la matriz de confusión permite distinguir errores esperables entre clases vecinas de confusiones más graves entre extremos.

Un cuidado a tener en cuenta, visible incluso en un vistazo exploratorio inicial a los datos, es que mezclar todo el año en un solo modelo combina calefacción, enfriamiento y días de baja operación, lo que diluye la relación clima–consumo: por debajo de los 15 °C hay tanto días de consumo bajo como alto (calefacción), lo que satura de “ruido” el panel izquierdo de la Figura 1.

Al restringir el análisis a días de temperatura exterior media ≥ 15 °C (“días de enfriamiento”, panel derecho), el color se ordena de forma mucho más clara de verde a rojo a medida que sube la temperatura. Esto sugiere acotar el problema a ese régimen antes de modelar.




Figura 1: Consumo HVAC diario vs temperatura exterior, coloreado por clase de consumo. Izquierda: todos los días hábiles válidos de 2018–2019 (n=477). Derecha: solo días de temperatura media ≥ 15 °C (n=163).

Además de observar la temperatura exterior directamente, se generó una reducción de variables climáticas para resumir las condiciones exteriores en un único índice de favorabilidad energética. Este índice combina temperatura, humedad, punto de rocío y radiación solar, y permite visualizar si los días con condiciones exteriores más favorables tienden a asociarse con menor consumo HVAC.




Figura 2: Condiciones exteriores reducidas frente al consumo HVAC. El eje horizontal resume las condiciones climáticas del día en un índice de favorabilidad energética, mientras que el eje vertical muestra el consumo HVAC observado.

Como método se propone una regresión logística multiclase sobre variables climáticas estandarizadas (temperatura media/máxima/mínima, humedad relativa media, punto de rocío medio, radiación solar media), por ser interpretable: sus coeficientes permitirían leer qué variable climática empuja hacia cada clase. Antes de confiar en ese modelo habría que tener dos cuidados puntuales: las variables climáticas están correlacionadas entre sí (temperatura, punto de rocío y humedad se mueven juntas), lo que puede afectar la lectura de los coeficientes individuales. Dado que tras filtrar por régimen la muestra quedaría chica (del orden de un año de días hábiles de enfriamiento para entrenar), conviene comparar la regresión logística contra al menos un modelo no lineal.

Un árbol de decisión (CART) es un candidato natural para esa comparación. A diferencia de la regresión logística, que asume una combinación lineal fija de las variables, CART parte el espacio con cortes binarios sucesivos sobre una variable a la vez (del tipo “temperatura $\geq c$ ”), sin necesidad de asumir de antemano ninguna forma funcional, lo que le permite capturar relaciones no lineales e interacciones entre variables climáticas de forma automática. Esto es relevante porque la Figura 1 ya muestra que la relación clima-consumo no es perfectamente lineal. En el material del curso, se usó como ejemplo de CART un problema con la misma estructura que el nuestro (predecir nivel de ozono a partir de fecha, radiación solar, viento y temperatura), lo que sugiere que un árbol es una elección razonable frente a variables climáticas.

El cuidado es que un árbol individual es, según el mismo material, “fácil de interpretar pero muy inestable: un pequeño cambio en la muestra lleva a resultados completamente distintos”. En nuestro caso, esto es un riesgo concreto, ya que contamos con solo ~ 69 días de entrenamiento.

Random forest existe justamente para atacar ese problema: promedia muchos árboles entrenados sobre remuestreos de los datos (bagging), reduciendo la varianza que un árbol solo no puede evitar. Breiman (autor de CART y random forest) agrega un argumento adicional en su trabajo *The Two Cultures*: cuando las variables predictoras están correlacionadas entre sí, como pasa acá con temperatura, punto de rocío y humedad, los métodos algorítmicos como random forest pueden dar una lectura de importancia de variables más confiable que un modelo lineal, porque reparten la señal entre variables correlacionadas de forma distinta en cada árbol del bosque, en vez de concentrarla (a veces de forma contraintuitiva) en los coeficientes de un único ajuste lineal.

Con esto en mente, conviene entrenar los tres modelos (regresión logística, árbol, random forest) sobre el mismo split y reportar el error estándar de las métricas, para no confundir una diferencia real entre modelos con ruido propio de una muestra de prueba pequeña. Para explicar los resultados finales se usarían una matriz de confusión (para ver en qué clases se equivoca el modelo) y un gráfico de la magnitud de los coeficientes o de la importancia de variables (para explicar qué condiciones climáticas pesan más en la clasificación).

4. Consideraciones éticas

Privacidad. El dataset no identifica personas directamente, pero incluye variables de ocupación y uso de WiFi que, aunque no se usarían en el modelo propuesto, podrían en principio revelar patrones de presencia de individuos específicos (horarios de llegada/salida) si se cruzan con otras fuentes. Cualquier extensión del proyecto que incorpore esas variables debería aplicar minimización de datos (agregar por piso o zona, no por persona) y evitar identificadores directos, siguiendo los principios de anonimización vistos en el curso.

Sesgos. El modelo se entrenaría con un único edificio, clima y período (2018–2019, excluyendo 2020 por atípico), por lo que no generalizaría a otros climas, tipos de edificio o patrones de ocupación. Usarlo fuera de ese contexto sería aplicar un modelo sesgado por una muestra no representativa. También habría sub-representación de regímenes extremos (p. ej. el propio 2020), que quedarían mal clasificados si se reintrodujeran sin ajustar el modelo.

Impacto potencial. Un modelo que etiqueta días de “alto consumo” es útil para planificación energética, pero mal usado podría motivar recortes automáticos de climatización sin considerar el confort de las personas que ocupan el edificio, las cuales no tienen visibilidad ni control sobre esa decisión.

Mitigación. Frente a estos riesgos, conviene mantener siempre una persona en el loop para las decisiones operativas, de forma que ningún recorte de HVAC se automatice sin supervisión. También sería importante monitorear el confort y la temperatura interior junto con las predicciones del modelo, para detectar a tiempo cualquier efecto negativo sobre los ocupantes, y ser transparente con ellos respecto a qué datos se recolectan y con qué fin. Por último, dado que el nivel general de consumo del edificio podría cambiar de un año a otro por motivos operativos, el modelo debería revalidarse periódicamente en vez de asumirse válido de manera indefinida.