Introducción a la Ciencia de Datos

INFORME TAREA 1: Análisis exploratorio de noticias

Bruno Fabre Hernandez
Santiago Burgeño Paysse

14 de Mayo 2026

Índice

1. Cargado y Limpieza de Datos **3**
A. Exploración inicial y datos faltantes 3
B. Evolución temporal de la cobertura 5
C. Normalización del texto 6
D. Elección de campos de texto 7
E. Pistas identificadoras del medio 7
F. Restricción por sección o período temporal 9

2. Conteo de Palabras y Visualizaciones **9**
A. Palabras más frecuentes por medio 9
B. Volumen de palabras por medio 10
C. Matriz de menciones entre medios 10
D. Preguntas propuestas 11

3. Referencias **12**

1. Cargado y Limpieza de Datos

A. Exploración inicial y datos faltantes

Al cargar el dataset se obtiene un total de 30.213 filas.

Análisis de nulos:

La exploración inicial revela la presencia de valores faltantes en varias columnas:

Columna	Nulos	Porcentaje
author	11.405	37,7 %
section	10.232	33,9 %
article	1.176	3,9 %
url	141	0,5 %
publication	141	0,5 %
date	0	0,0 %
title	0	0,0 %

Cuadro 1: Análisis de nulos.

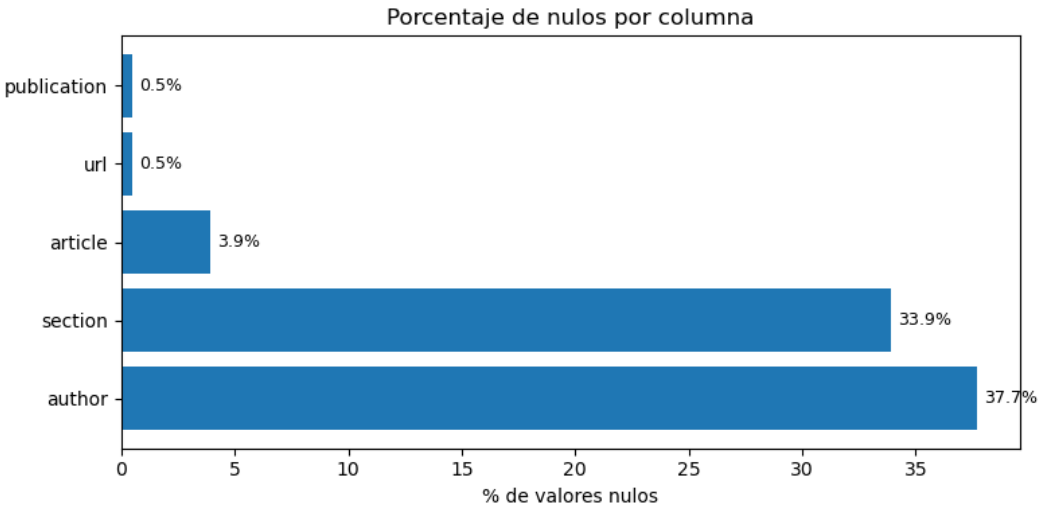

Figura 1: Porcentaje de nulos por columna.

La columna `author` resulta inutilizable para análisis de texto: medios como TMZ y The Economist presentan el 100 % de sus registros sin firma, CNBC el 99 %, Washington Post el 96 % y Reuters el 70 %. La columna `section` solo es completada de forma consistente por Reuters, CNN, The New York Times y People, lo que la vuelve poco comparable entre medios.

El caso más crítico es la columna `article`: Washington Post registra un 92,9 % de artículos sin contenido, lo que lo excluye del top 5 por artículos disponibles a pesar de tener muchas filas en el dataset. Las columnas `date` y `title`, en cambio, no presentan nulos y son las más confiables del dataset.

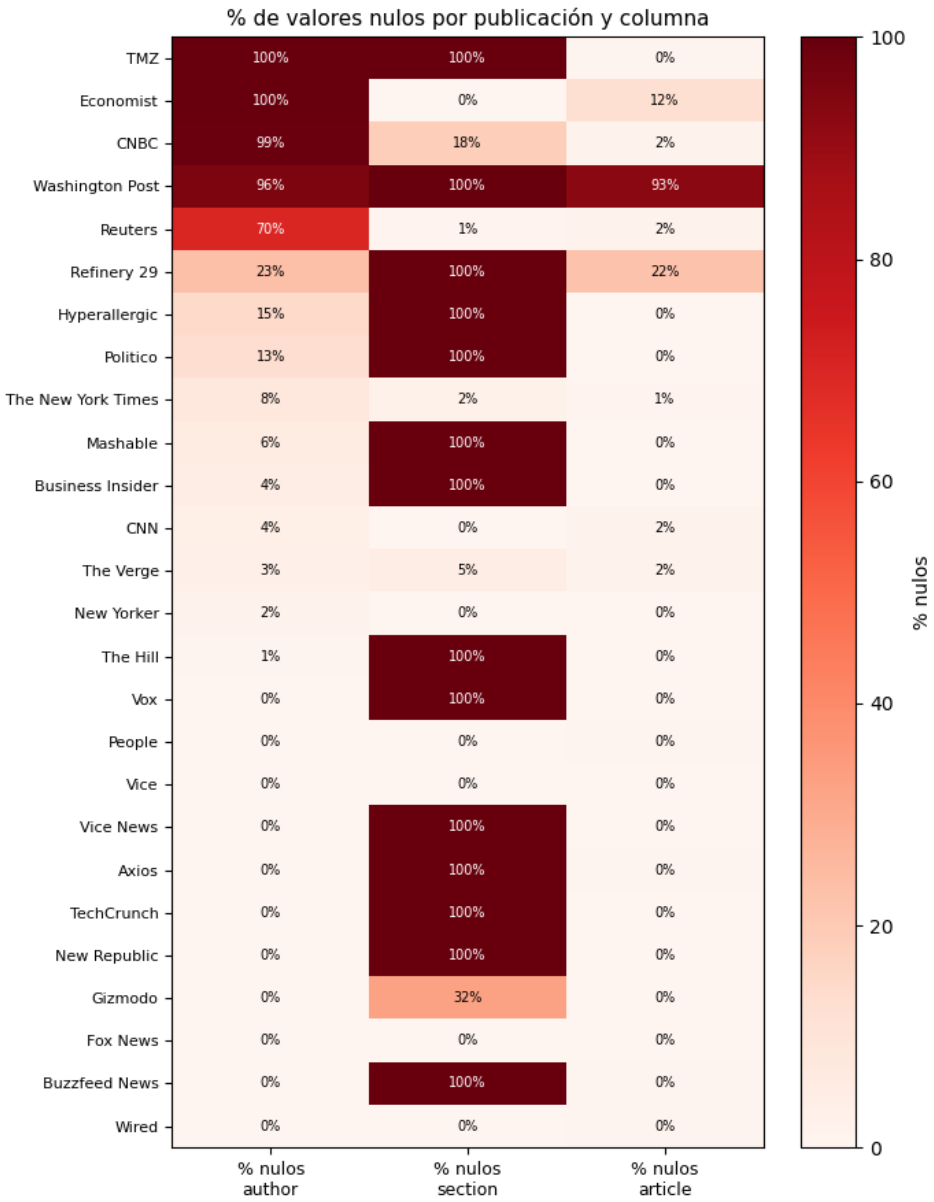

Figura 2: % de valores nulos por publicación y columna.

Problema de calidad en la columna `date`:

La columna `date` mezcla tres formatos distintos:

- '2018-02-02' (35,7 % de filas — solo fecha)
- '2018-12-27 19:20:08' (25,6 % — con hora real)
- '2017-04-03 00:00:00' (38,6 % — timestamp con hora en cero)

Esta heterogeneidad obliga a usar `pd.to_datetime(..., format='mixed')`. Sin ese parámetro, pandas falla al parsear 19.414 filas (64 % del dataset).

Análisis de duplicados:

Decisión sobre duplicados:

Se evaluaron dos criterios para identificar registros duplicados:

1. Criterio relajado (título + fecha + publicación): detecta 174 filas. El problema es que puede eliminar artículos distintos que comparten titular y fecha dentro del mismo medio.

2. Criterio conservador (todas las columnas, usando `date_day` normalizado en lugar de `date`): detecta 140 filas. Solo elimina registros donde todos los campos (excepto id y article_idx) son idénticos. En resumen, se considera que una fila es un duplicado de otra cuando contienen exactamente la misma información en las columnas date, year, month, day, author, title, article, url, section y publication.

Se eligió el criterio conservador: si el cuerpo del artículo (`article`) difiere entre dos filas, no puede considerarse un duplicado verdadero. Se utiliza `date_day` (columna creada que contiene la fecha sin hora) para evitar que '2018-10-15' y '2018-10-15 00:00:00' sean tratadas como fechas distintas cuando en realidad representan el mismo día.

Limpieza final:

Además de los duplicados, se procedió a eliminar títulos del tipo "Not Found" y artículos vacíos, ya que en ambos casos se trataba de filas que, o bien no aportan información o parecen ser errores al obtener el dato en el dataset usado. Los pasos se detallan a continuación:

Paso	Filas eliminadas	Filas restantes
Dataset original	–	30.213
Duplicados exactos (todas las columnas)	140	30.073
Títulos "Not Found" (CNBC)	13	30.060
Artículos vacíos (article = NaN)	1.023	29.037

Cuadro 2: Limpieza final.

Nota: existe solapamiento entre pasos (varios duplicados también tenían article vacío), por lo que el total eliminado es 1.176 y no la suma de las partes.

Top 5 medios con mayor cantidad de artículos (dataset limpio):

Medio	Artículos
Reuters	9.266
The New York Times	2.805
CNBC	2.578
The Hill	2.349
People	1.522

Cuadro 3: Top 5 medios con mayor cantidad de artículos.

A partir de este punto, todo el análisis se realiza sobre estos cinco medios.

B. Evolución temporal de la cobertura

El análisis temporal revela las siguientes tendencias:

- Reuters domina ampliamente el volumen de publicación con actividad sostenida durante todo el período (∼9.300 artículos en total, frente a ∼1.500–2.800 de cada uno de los demás medios).
- The New York Times y The Hill mantienen niveles estables y comparables a lo largo de todo el período analizado.
- People es el medio con menor volumen y mayor estabilidad, coherente con su perfil de revista de entretenimiento que no responde a picos de coyuntura política o económica.
- Se observa una caída general en la producción durante 2020, que probablemente sea un artefacto del muestreo del dataset original y no un fenómeno editorial real.

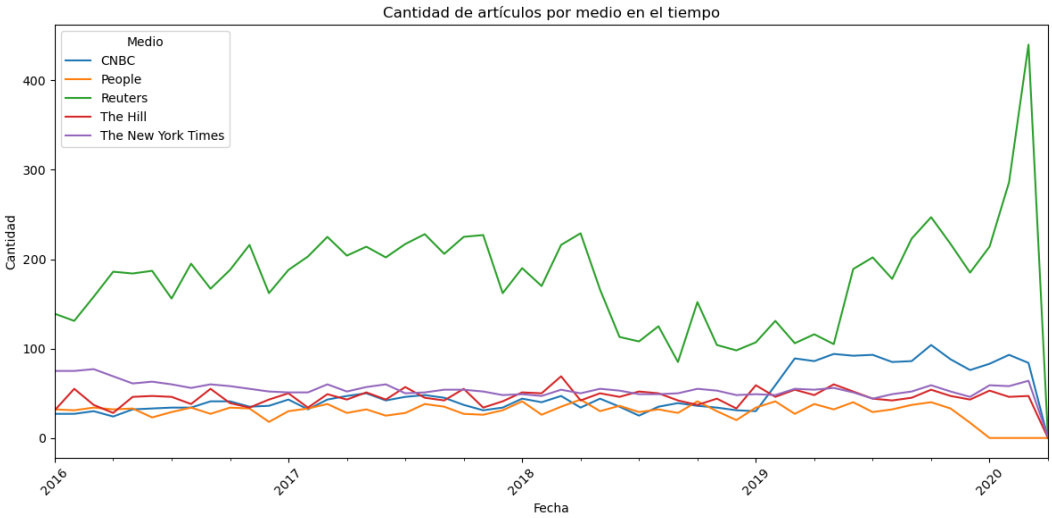

Figura 3: Cantidad de artículos por medio en el tiempo.

C. Normalización del texto

La función `clean_text` aplica las siguientes transformaciones, cada una justificada a continuación:

Transformación	Justificación
Eliminar dateline del artículo	Los artículos de Reuters comienzan con una línea tipo "LONDON, Feb 2 (Reuters) -". El regex `^[^\n]*\n` se aplica sobre article antes de concatenar con el título. Si se aplicara después, `^` apuntaría al inicio del título y el dateline nunca sería eliminado.
Convertir a minúsculas	Normaliza "President", "president." y "president," como una única forma de la misma palabra.
Eliminar URLs	Las URLs contienen el dominio del medio (thehill.com, etc.), lo que constituye una pista identificadora directa y trivial que distorsionaría cualquier análisis de estilo.
Eliminar puntuación (`[^a-z0-9\s]`)	Normaliza "president.", "president," y "president" a una sola forma. El uso de regex es más robusto que reemplazar caracteres de puntuación uno por uno.
Colapsar espacios múltiples	Limpia los residuos dejados por los pasos anteriores. Produce texto uniforme listo para tokenizar.

Cuadro 4: Transformaciones aplicadas por la función `clean_text`.

Nota: el regex de dateline se aplica sobre la columna `article` antes de concatenar con `title`. Este orden es esencial: si se aplicara sobre el string ya combinado, `^` apuntaría al inicio del título (no al dateline del artículo) y la transformación no tendría efecto. Este fue un bug identificado y corregido durante el desarrollo del análisis.

D. Elección de campos de texto

Se evaluaron tres alternativas para definir el campo de texto de trabajo:

- Solo `article`: ofrece mayor detalle y extensión, pero puede contener más ruido y artefactos de formato (datelines, boilerplate, plantillas).
- Solo `title`: resume el tema principal de cada nota, pero es demasiado breve y a menudo ambiguo para capturar el estilo del medio.
- Combinación `title + article`: captura tanto el tema central como el contenido detallado del artículo.

Decisión: se trabaja con la combinación de ambos campos. Esta opción ofrece una representación más completa y equilibrada: el título aporta la síntesis temática y el artículo aporta el desarrollo, el vocabulario y el estilo característico de cada medio.

E. Pistas identificadoras del medio

Se analizaron dos tipos de señales que podrían identificar directamente al medio de prensa sin necesidad de clasificación real por estilo.

Presencia de URLs en el cuerpo original del artículo:

Medio	% artículos con URL
The Hill	9,6 %
People	4,3 %
CNBC	3,7 %
Reuters	1,1 %
The New York Times	0,3 %

Cuadro 5: Presencia de URLs en el cuerpo original del artículo.

Porcentaje de artículos con auto-mención (nombre del medio en su propio CleanText):

Medio	% auto-mención
The Hill	99,4 %
Reuters	90,2 %
People	68,4 %
CNBC	35,1 %
The New York Times	17,2 %

Cuadro 6: Porcentaje de artículos con auto-mención.

Frecuencia de cada nombre de medio en el cuerpo completo:

Patrón buscado	% de artículos que lo contienen
"reuters"	50,2 %
"people"	32,1 %
"the hill"	12,9 %
"cnbc"	5,2 %
"new york times"	4,5 %

Cuadro 7: Frecuencia de cada nombre de medio en el cuerpo completo.

Análisis de los hallazgos:

1. Reuters aparece en el 50 % de todos los artículos porque es una agencia de noticias (wire service): otros medios citan habitualmente sus despachos, y sus propios artículos siempre incluyen el dateline de agencia del tipo "LONDON (Reuters) -".

2. The Hill registra auto-mención en el 99,4 % de sus artículos. Esto no refleja contenido editorial: el nombre aparece en una plantilla de pie de página repetida en cada artículo ("The Hill 1625 K Street NW..."). Es un artefacto de formato, no una señal de estilo.

3. El patrón "people" es un sustantivo común del inglés. El 32 % de artículos que lo contienen no representan referencias reales a la revista People. Para identificar menciones genuinas habría que buscar "people magazine" o "people.com".

4. The New York Times es el medio con el perfil más "limpio": baja auto-mención (17,2 %), casi sin URLs en el texto (0,3 %), y poco citado por otros medios (4,5 %). Refleja un estilo formal y tradicional con menos artefactos digitales.

Decisión: se mantienen estas pistas durante la etapa exploratoria actual, ya que en este punto el objetivo es análisis descriptivo, no clasificación. De cara a una tarea de clasificación futura, convendría eliminar los datelines de Reuters y el boilerplate de The Hill, o bien usar TF-IDF para reducir automáticamente el peso de estas señales triviales y forzar al modelo a aprender señales de estilo más genuinas.

F. Restricción por sección o período temporal

No se implementó ninguna restricción, pero se evaluaron sus implicaciones para decisiones futuras.

Ventajas de restringir el análisis:

- Permite una comparación más homogénea entre medios (mismo tema o período), controlando el efecto de la temática sobre el análisis.
- Reduce el riesgo de que un clasificador futuro aprenda a distinguir temas en lugar del estilo propio de cada medio.
- Produce resultados más interpretables al aislar el factor de estilo.

Desventajas de restringir el análisis:

- Reduce significativamente la cantidad de datos disponibles por medio.
- Elimina variabilidad real en el comportamiento editorial de cada publicación.
- Limita la capacidad de generalización del modelo a contextos temáticos o temporales distintos a los del subconjunto elegido.

En el estado actual del análisis, trabajar con el cuerpo completo es preferible para mantener la mayor cantidad de datos y capturar la variabilidad natural de cada medio. La restricción sería más justificada si se detectara que las diferencias temáticas dominan sobre las diferencias de estilo en los resultados.

2. Conteo de Palabras y Visualizaciones

A. Palabras más frecuentes por medio

Al analizar las palabras más frecuentes de cada medio, el hallazgo principal es que las posiciones más altas están dominadas por stopwords del inglés: `the`, `a`, `of`, `to`, `in`, `said`, etc. Estas palabras son comunes a todos los medios y no aportan información diferencial sobre el estilo o la temática de cada publicación. Esto impide encontrar diferencias entre medios con este enfoque directo de frecuencias brutas.

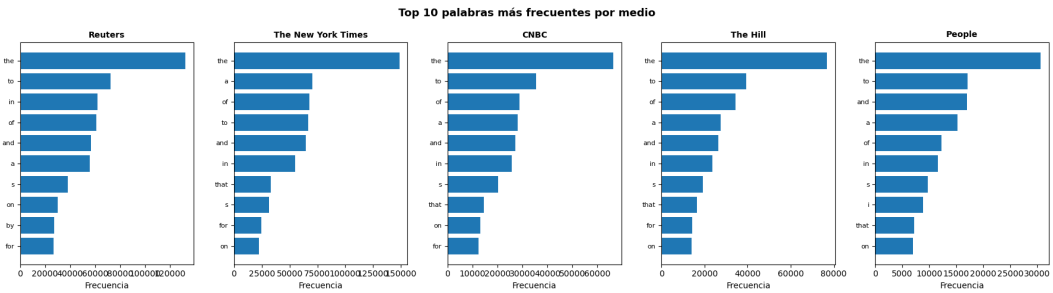

Figura 4: Top 10 palabras más frecuentes por medio.

Ideas para mejorar la visualización (sin implementar):

1. Por sección temática: filtrar por la columna `section` antes de contar, para comparar medios dentro del mismo campo temático (política, economía, etc.). Esto reduciría el ruido introducido por diferencias de cobertura.

2. Por período temporal: calcular el top de palabras por año o trimestre, para detectar eventos con vocabulario diferencial (por ejemplo, vocabulario asociado a elecciones o crisis económicas).

3. Eliminar stopwords: usar listas estándar (como `nltk.corpus.stopwords`) para hacer emerger las palabras temáticamente relevantes y comparables entre medios.

4. TF-IDF: identificar palabras que son frecuentes en un medio pero raras en los demás. Esta métrica captura vocabulario verdaderamente distintivo de cada publicación, independientemente de la frecuencia absoluta.

B. Volumen de palabras por medio

El ranking de medios por total de palabras refleja principalmente el volumen de artículos disponibles de cada medio, no necesariamente el estilo de escritura. Reuters lidera el total (∼9.300 artículos) aunque sus artículos individuales sean más breves que los de The New York Times o CNBC.

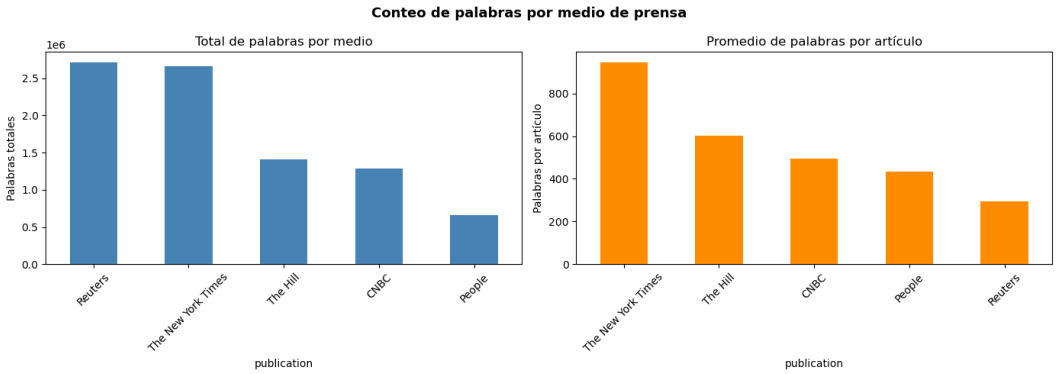

Figura 5: Conteo de palabras por medio de prensa.

Para obtener una medida que caracterice el estilo editorial de cada medio con independencia de su volumen, se proponen las siguientes alternativas:

1. Promedio de palabras por artículo: mide la extensión típica de cada nota, independientemente del número total de artículos del medio.

2. Eliminación de stopwords antes de contar: el total de palabras con contenido semántico es más informativo que el total bruto.

3. Normalización por cantidad de artículos: cualquier métrica de volumen debe reportarse tanto en valor absoluto como normalizada para ser interpretable.

C. Matriz de menciones entre medios

Se construyó una matriz 5×5 donde la entrada (i, j) indica el número de artículos del medio i que contienen el nombre del medio j en su texto limpio.

Medio que menciona ↓ / Medio mencionado →	Reuters	NYT	CNBC	The Hill	People
Reuters	8.354	32	31	5	1.517
The New York Times	45	530	13	37	1.599
CNBC	821	52	906	7	812
The Hill	71	163	13	2.335	970
People	4	50	3	8	1.041

Cuadro 8: Matriz de menciones entre medios.

Observaciones:

- Reuters es el medio más citado: aparece en el 50 % del cuerpo total. CNBC lo menciona en 821 artículos, resultado coherente con la cobertura financiera que habitualmente cita a Reuters como fuente primaria.
- The Hill registra 2.335 auto-menciones en 2.349 artículos totales: como se señaló en la Parte 1E, el nombre del medio está presente en una plantilla de pie de página repetida en prácticamente cada artículo. Es un artefacto de formato, no una señal de comportamiento editorial.
- La columna "People" presenta valores llamativamente altos para otros medios (Reuters: 1.517, The New York Times: 1.599, The Hill: 970). Estos números no representan menciones reales a la revista People, sino usos ordinarios de la palabra "people" en inglés. Esta columna debe interpretarse con cautela y su uso como señal identificatoria no es confiable.
- The New York Times y CNBC presentan auto-menciones relativamente bajas (530 y 906 respectivamente), lo que sugiere que sus textos no contienen plantillas repetidas con el nombre del medio, a diferencia de Reuters y The Hill.

D. Preguntas propuestas

A continuación se proponen tres preguntas que podrían responderse a partir de este dataset, junto con un posible camino de análisis para cada una.

1. ¿En qué días de la semana publica más cada medio?

   Camino: aplicar `groupby` sobre `date.dt.dayofweek` y contar artículos por día para cada publicación. Esta pregunta puede revelar si agencias como Reuters publican los 7 días de la semana (comportamiento esperado de un wire service) mientras que medios tradicionales como The New York Times o The Hill reducen su producción durante el fin de semana. También podría evidenciar si People mantiene una cadencia semanal regular más acotada.

2. ¿Ha cambiado el foco temático de cada medio a lo largo del tiempo?

   Camino: dividir los artículos por año o trimestre y calcular el top de palabras o métricas TF-IDF por período para cada medio. Esto permitiría detectar eventos clave (elecciones presidenciales, crisis económicas, pandemias) y evaluar si los distintos medios los cubrieron con el mismo vocabulario o con énfasis distintos. Comparar los vectores TF-IDF entre períodos daría una medida cuantitativa del "cambio de agenda".

3. ¿Qué tan similar es el vocabulario entre pares de medios?

Camino: construir un vector TF-IDF por medio (tratando a cada medio como un único "documento" agregado de todos sus artículos) y calcular la similitud coseno entre todos los pares. Los medios con vocabulario más similar serían más difíciles de distinguir en una clasificación automática, lo que daría una estimación anticipada de la dificultad esperada de esa tarea. Si Reuters y CNBC resultaran muy similares (ambos con cobertura económica y financiera), esto alertaría sobre posibles errores de clasificación entre ellos.

3. Referencias

- Dataset: *All the News 2.1 – Component One.*
- Notebook de análisis: `2026_template_tarea1.ipynb`.
- Curso: Introducción a la Ciencia de Datos, edición 2026.